Estudios Transcriptómicos Masivos: Análisis de Microarrays

Fran(cisco J.) Romero-Campero



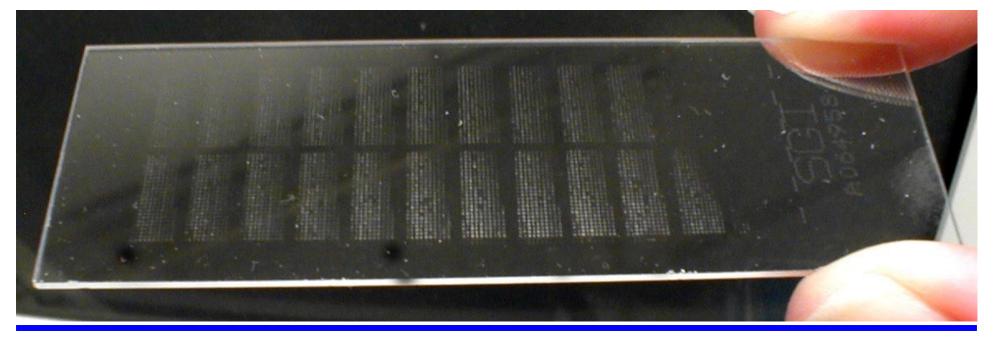




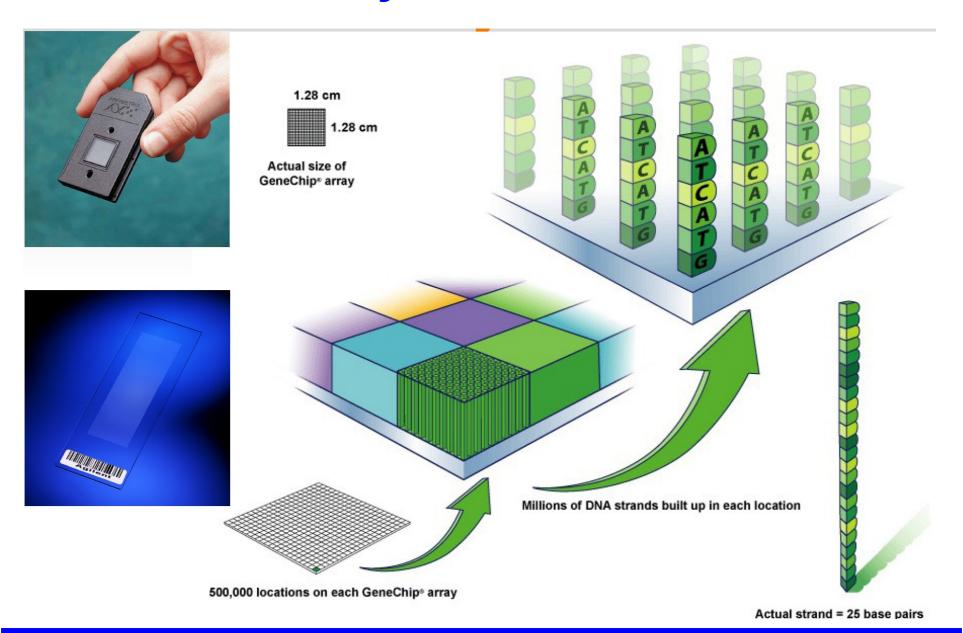
Dpt. de Ciencias de la Computación e Inteligencia Artificial Instituto de Bioquímica Vegetal y Fotosíntesis Universidad de Sevilla



- Los microarrays o micromatrices son la tecnología de altas prestaciones clásoca que permiten medir los niveles de expresión génicos en una muestra estimando el número de transcritos (mRNA).
- Un microarray es un soporte sólido donde se disponen en forma de matriz (en una distribución regular de filas y columnas) secuencias de DNA llamadas sondas (probes en inglés) que son complementarias a las secuencias de los transcritos conocidos en una especie en particular.









- El uso más común de los microarrays consiste en extraer el mRNA de muestras de interés a comparar. Por ejemplo, un tejido con un tratamiento especial y otro sin el tratamiento o una muestra del tipo silvestre y otra de un mutante.
- Normalmente este mRNA se convierte a cDNA, se etiqueta con fluorescencia o radioactividad y se coloca sobre el microarray para que hibride de forma específica con las correspondientes secuencias de DNA.
- Tras lavar el microarray podemos estimar el número de transcritos que han hibridado y así obtener una medida global del nivel de expresión de los distintos genes a partir de la fluorescencia detectada.





Ventajas

- Relativamente baratos.
- Protocolos de laboratorio bien definidos y depurados.
- Amplia variedad de herramientas de análisis bien establecidas y testeadas.

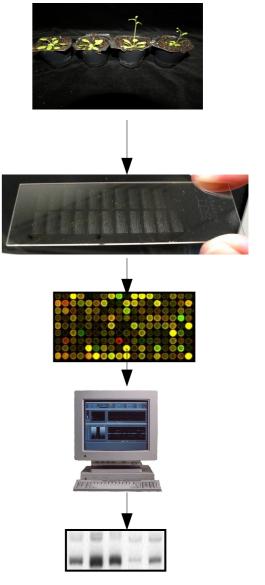
Desventajas

- Limitaciones a transcritos conocidos.
- Sensibilidad limitada debido a saturación de las sondas.
- Problemas de hibridación.
- Problemas de diseño.



Fases del Estudio Transcriptómico basado en Microarrays

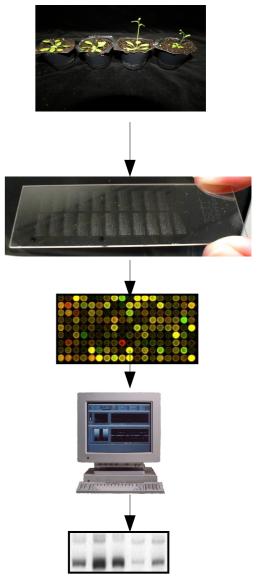
- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.





Fases del Estudio Transcriptómico basado en Microarrays

- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.





Fase 1: Diseño Experimental

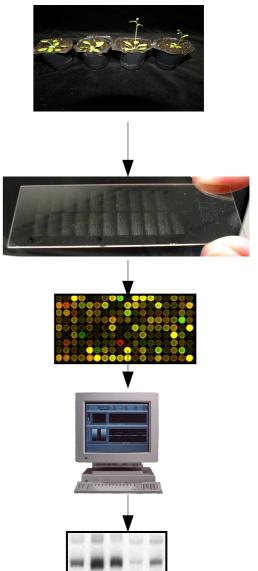
- Esta es la fase más importante del estudio ya que es donde pueden producirse la mayor parte de los **errores irreparables**.
- Aquí se seleccionan las distintas condiciones a comparar y se fijan controles
 - Muestras de distintos tejidos.
 - Muestras sometidas a distintas condiciones o tratamientos.
 - Muestras provenientes de distintos genotipos.
 - Muestras provenientes de series temporales.
- Decidir y diseñar diferentes <u>réplicas</u>:
 - Replicas técnicas o experimentales
 - Réplicas biológicas





Fases del Estudio Transcriptómico basado en Microarrays

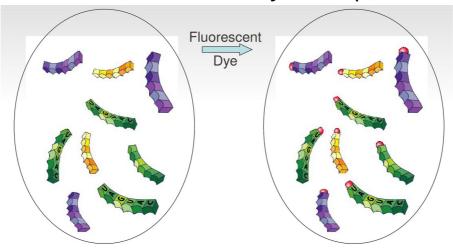
- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.





Fase 2: Extracción del RNA y Preparación

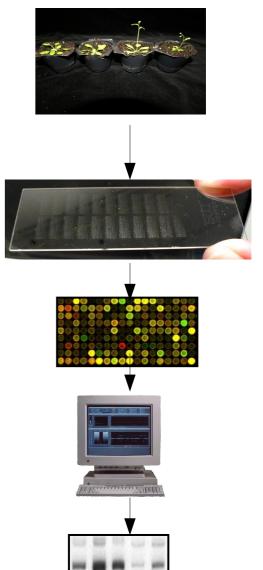
- Para la extracción del RNA de una muestra se suelen utilizar reactivos tales como el TRIzol (Invitrogen) posiblemente seguidos de pasos extras para la purificación como la eliminción de DNA genómico o extracción polyA.
- Es crítico tomar las diferentes muestras y extraer el RNA **bajo las mismas condiciones** que no se analizan en el experimento.
- Es necesario analizar la pureza y calidad del RNA con el espectrofotómetro mediendo la razón a260/a280, a260/a230 ,~ 1.7 – 2.0 (absorbancia ácidos nucléicos vs proteína, otros contaminantes), por electroforesis en gel.
- Seguidamente el RNA se convierte en cDNA y se etiqueta con un marcador fluorescente.





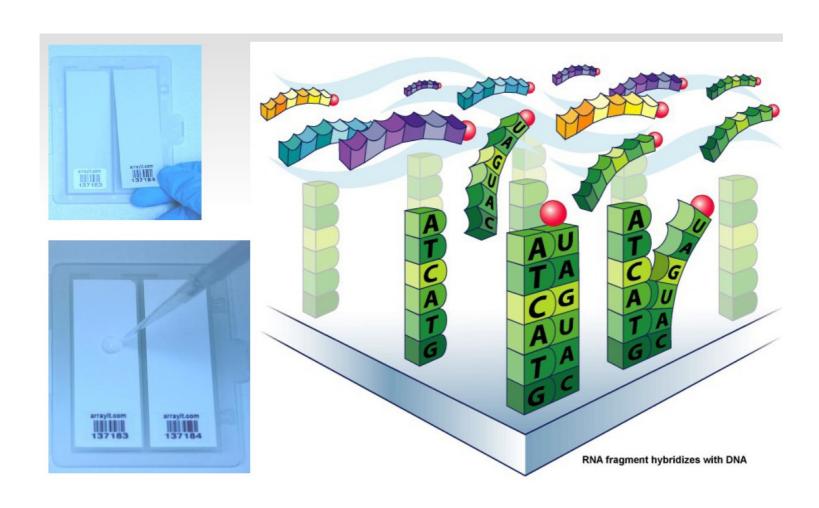
Fases del Estudio Transcriptómico basado en Microarrays

- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.



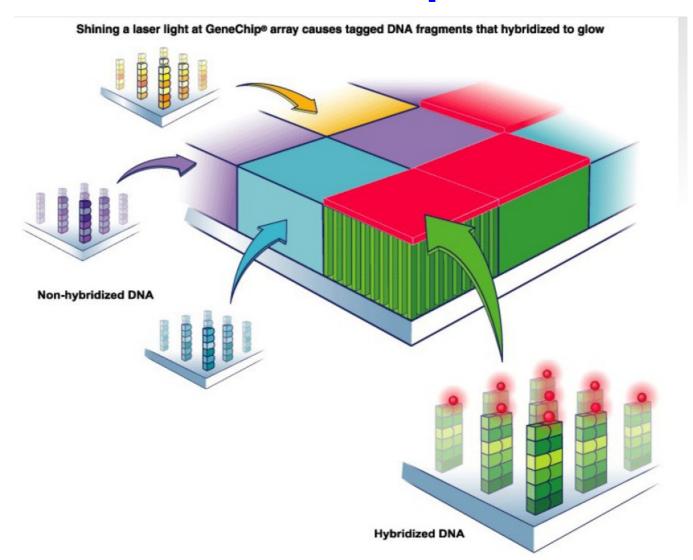


Fase 3: Hibridación de las muestras etiquetadas





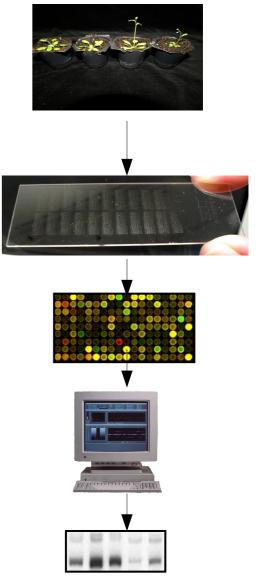
Fase 3: Hibridación de las muestras etiquetadas





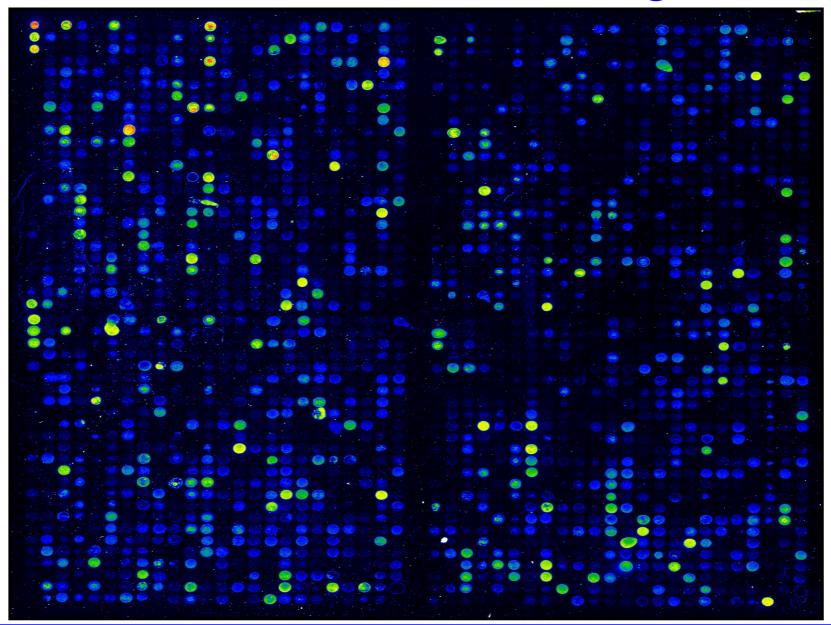
Fases del Estudio Transcriptómico basado en Microarrays

- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.



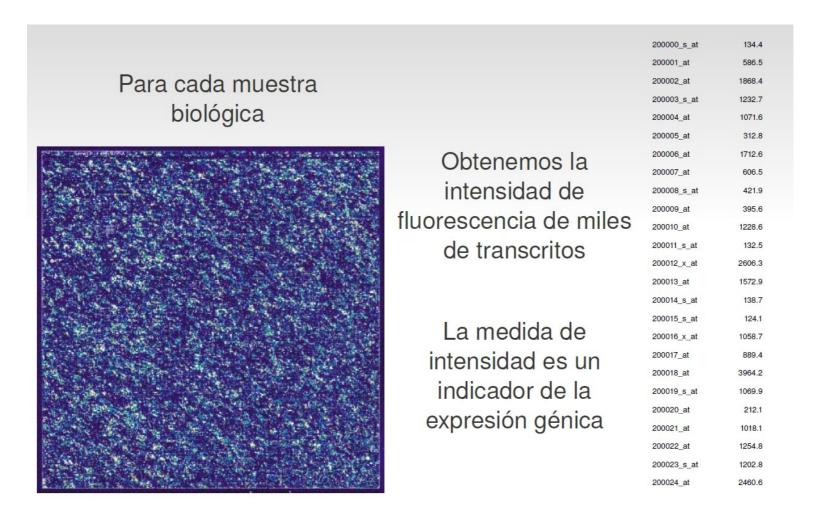


Fase 4: Análisis de Imágenes





Fase 4: Análisis de Imágenes

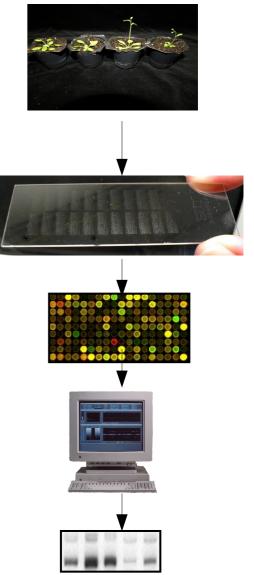


Trabajaremos con microarrays diseñados por la affymetrix cuyos datos brutos no procesados suelen aparecer en formato CEL



Fases del Estudio Transcriptómico basado en Microarrays

- Fase 1: Diseño Experimental.
- Fase 2: Extracción del RNA y preparación.
- Fase 3: Hibridación de las muestras etiquetadas.
- Fase 4: Análisis de imágenes.
- Fase 5: Análisis matemático-computacional de los datos.
- Fase 6: Confirmación o validación biológica.





MATERIALES:

La comunidad científica persigue hacer disponible libremente los datos transcriptómicos en bases de datos tales como **GEO**:

http://www.ncbi.nlm.nih.gov/geo/

con el doble objetivo de garantizar la reproduccibilidad de los resultados científicos y facilitar el desarrollo incremental de la ciencia donde unos resultados se basan en resultados previos.

Series GSE21582 Query DataSets for GSE21582 Status Public on Dec 01, 2010 Title Expression analysis of pye-1 mutants and root pericycle cells to iron sufficient or iron deficient conditions Organism Arabidopsis thaliana Experiment type Expression profiling by array Summary This SuperSeries is composed of the SubSeries listed below. Overall design Refer to individual Series Long TA, Tsukagoshi H, Busch W, Lahner B et al. The bHLH transcription factor POPEYE Citation(s) regulates response to iron deficiency in Arabidopsis roots. Plant Cell 2010 Jul;22(7):2219-36. PMID: 20675571 Submission date Apr 28, 2010 Last update date Jun 12, 2017 Contact name Terri Anita Long E-mail(s) tlong@duke.edu Phone 919-613-8202 919-613-8177 Organization name Duke University Department Biology Philip Benfey Street address Box 90338 Durham City State/province ZIP/Postal code 27707 Country USA Platforms (1) GPL198 [ATH1-121501] Affymetrix Arabidopsis ATH1 Genome Array Samples (10) GSM535984 Arabidopsis, WT, +Fe, replicate 1 ■ More... GSM535985 Arabidopsis, WT, +Fe, replicate 2

GSM535986 Arabidopsis, WT, -Fe, replicate 1



MÉTODOS:

R constituye una plataforma de software libre para el *análisis estadístico* y *representación gráfica* de los resultados. Mantenido y desarrollo activamente por una gran comunidad de investigadores. Puede comunicarse de forma sencilla con otros lenguajes de programación como C, Java, FORTRAN, Python, Perl, etc.

Bioconductor es un proyecto de software libre colaborativo que consiste de una serie de paquetes de R. Originalmente se desarrolló para el análisis de datos de microarray pero en la actualidad cuenta con paquetes para el estudio de datos de secuenciación, ensayos celulares, ensayos de altas prestaciones, etc.

www.bioconductor.org

- > install.packages("BiocManager") #sólo la primera vez
- > BiocManager::install("nomber_paquete")



El análisis computacional básico de datos de microarrays se divide en los siguientes pasos:

- Paso 5.1: Análisis de la calidad
- Paso 5.2: Preprocesamiento de los datos.
- Paso 5.3: Estimación de los niveles de expresión.
- Paso 5.4: Selección de genes diferencialmente expresados.
- Paso 5.5: Anotación funcional.



El análisis computacional básico de datos de microarrays se divide en los siguientes pasos:

Paso 5.1: Análisis de la calidad

Quality control

Paso 5.2: Preprocesamiento de los datos.

Data Processing

Paso 5.3: Estimación de los niveles de expresión.

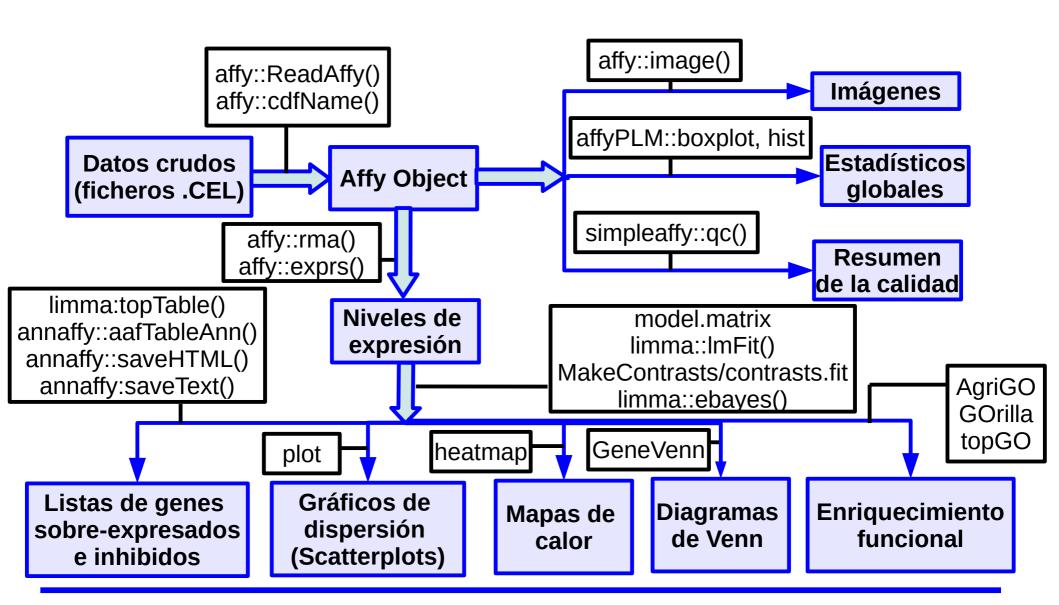
Paso 5.4: Selección de genes diferencialmente expresados.

Inferential Statistics

Paso 5.5: Anotación funcional.

Exploratory Analysis







Ejemplo: Estudio del Efecto Global en el Transcriptoma de *Arabidopsis thaliana* del gen *POPEYE* y el hambre de hierro

POPEYE codifica un factor de transcripción del tipo bHLH (basic helix loop helix) que en *Arabidopsis thalia*na regula la respuesta a deficiencia de hierro.



Estudiamos el efecto del gen POPEYE y la deficiencia de hierro. Tomamos las siguientes muestras con dos réplicas biológicas:

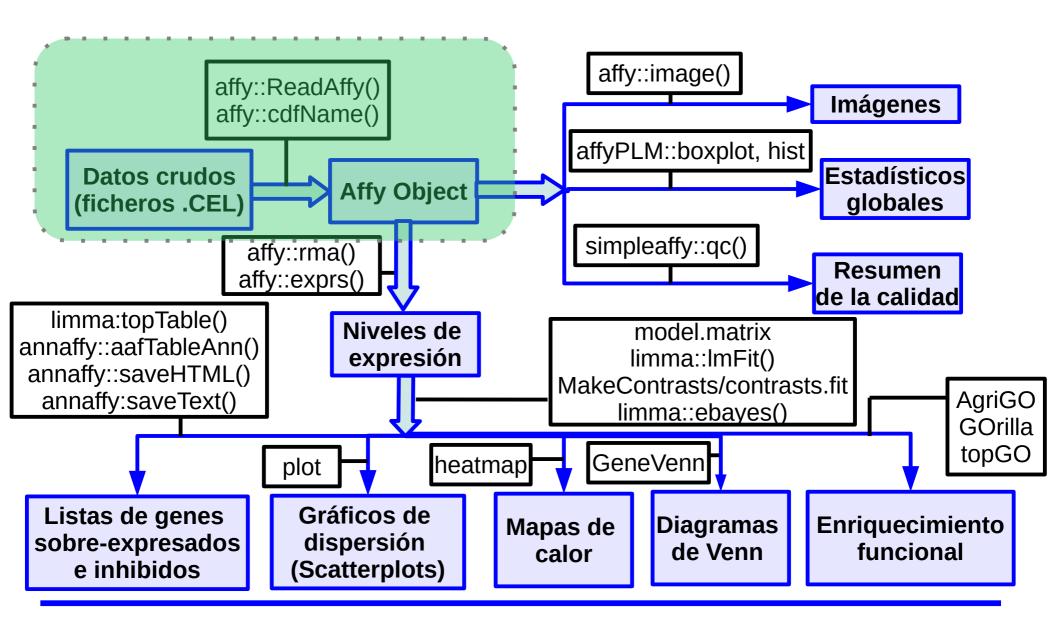
- WT con hierro
- WT sin hierro
- POPEYE con hierro
- POPEYE sin hierro



Long TA et al. The bHLH transcription factor POPEYE regulates response to iron deficiency in Arabidopsis roots. *Plant Cell* 2010 Jul;22(7):2219-36. Accession Number: GSE21582

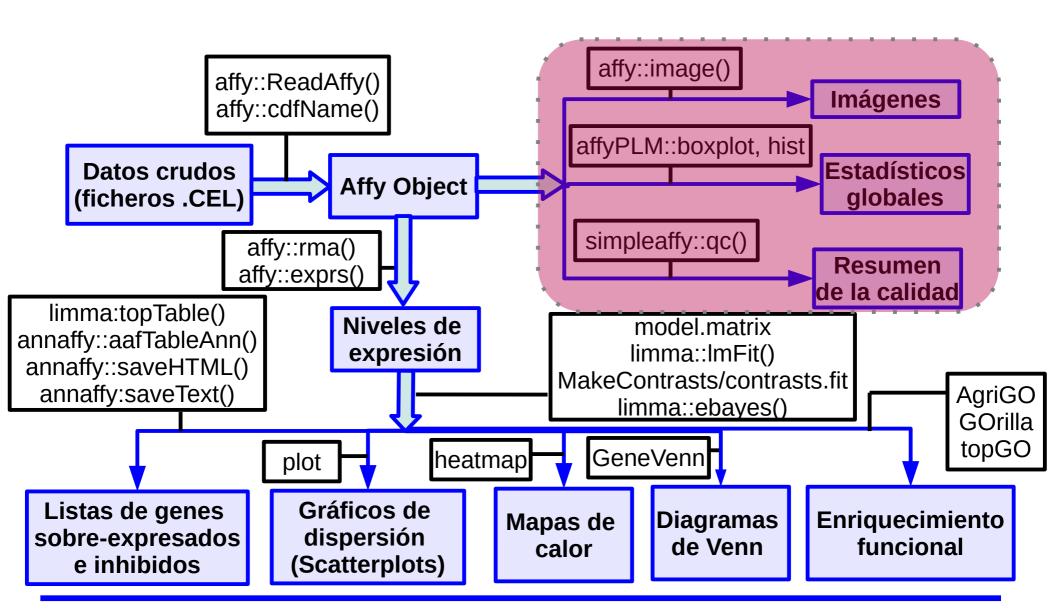


Paso 5.0: Lectura de Datos



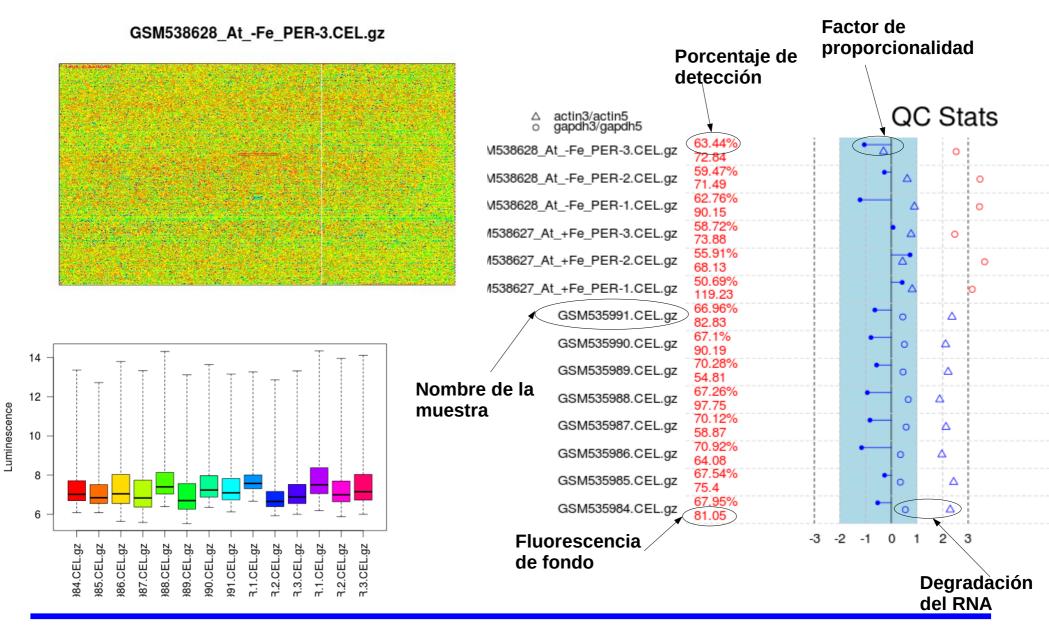


Paso 5.1: Análisis de la Calidad

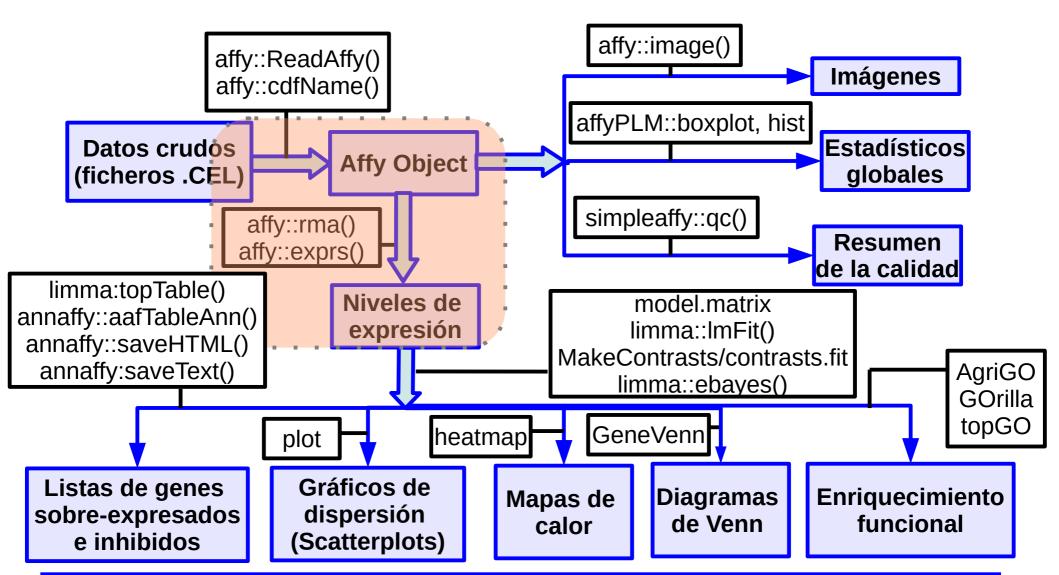




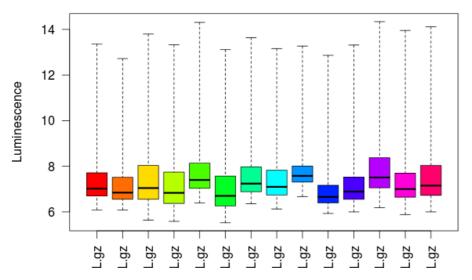
Paso 5.1: Análisis de la Calidad

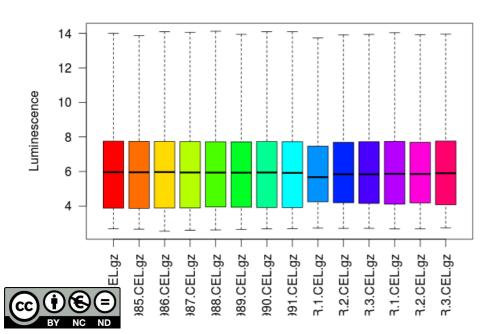








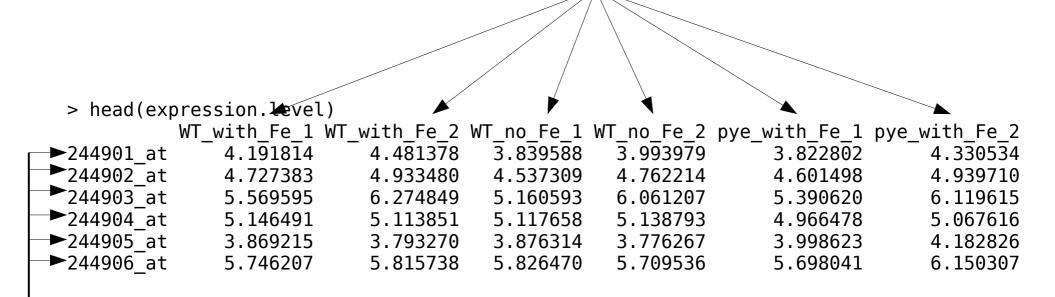




El principal objetivo del preprocesamiento de los datos consiste en eliminar el ruido producido por el sesgo de la técnia experimetnal utilizada (variabilidad experimental) a la vez que se conserva la variabilidad generada por la condición o fenotipo estudiado (variabilidad biológica).

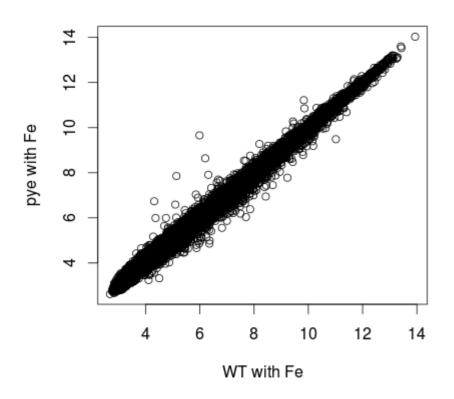
Robust Multiarray Analysis (RMA) es un algoritmo que realiza una corrección o sustracción de la fluorescencia de fondo, normalización de la fluorescencia de cada sonda y una estimación de los niveles de expresión de los genes representados por las distintas sondas del microarray utilizado.

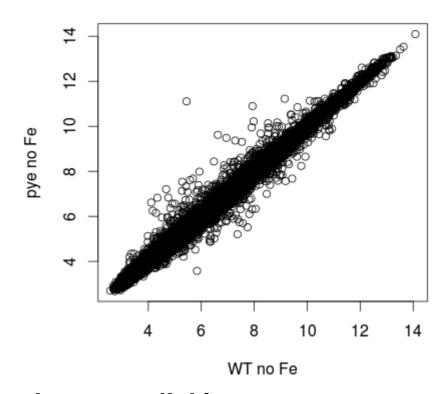
Las muestras se organizan por columnas



Los identificadores de las sondas que representan genes se organizan por filas



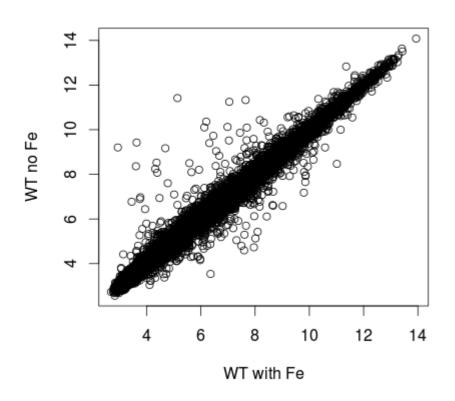


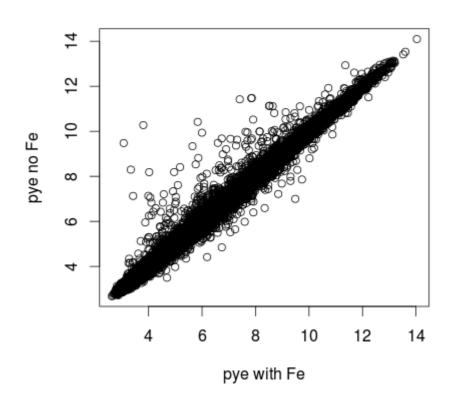


Comparación de dos genotipos en la misma condición aporta información sobre el efecto del cambio genotípico en respuesta a la condición estudiada.



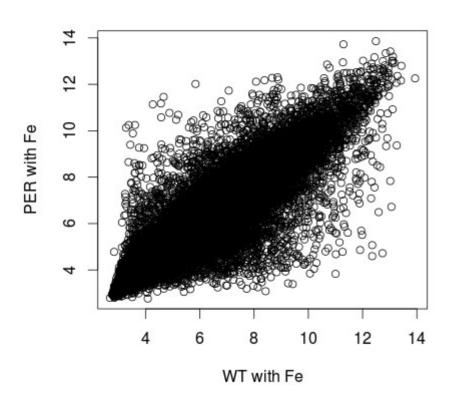
Paso 5.2: Preprocesamiento Paso 5.3: Estimación Niveles de Expresión

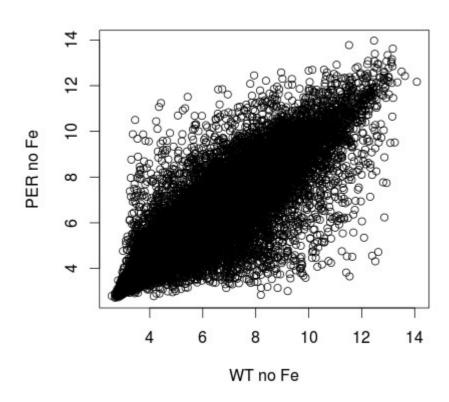




Comparación de un mismo genotipo en dos condiciones distintas aporta información sobre la respuesta del genotipo estudiado al cambio en las condiciones analizadas.



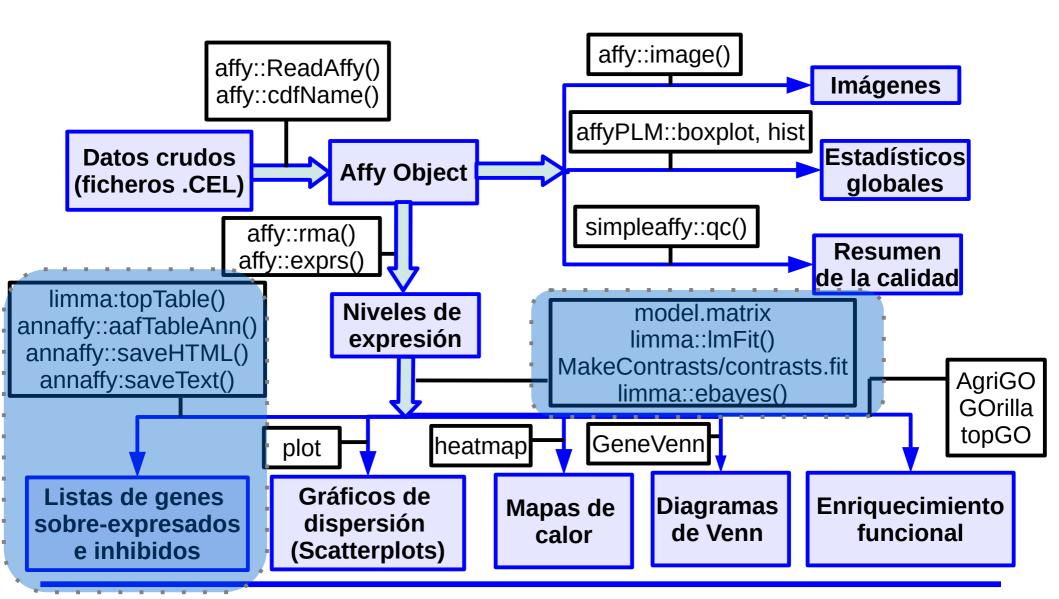




La comparación de dos tejidos diferentes en un organismos multicelular normalmente muestra una masiva diferencia en expresión génica.



Paso 5.4: Selección de Genes Diferencialmente Expresados





Paso 5.4: Selección de Genes Diferencialmente Expresados

Cuando se comparan los transcriptomas de dos genotipos diferentes o de un mismo genotipo bajo distintas condiciones existen diversos métodos para determinar genes expresados de forma diferencial o differentially expressed genes (DEGs) en inglés:

- **Método basado en el fold-change** (factor de proporcionalidad): Se fija un umbral para el fold-change típicamente 2, 4 u 8 que en log2 corresponde a 1, 2 ó 3. Los DEGs son aquellos que incrementan (o decrementan) su expresión por encima de dicho umbral (por debajo de menos dicho umbral). Este método es biológicamente interpretable de forma directa y no requiere un alto número de réplicas biológicas. Se aplica especialmente a estudios con organismo modelos donde no son necesarias muchas réplicas.
- Método basado en inferencia estadística: Para aplicar este método es necesario tener un alto número de réplicas biológicas. Para cada gen y para cada pareja de genotipos/condiciones a comparar se formula un contraste de hipótesis sobre igualdad de medias. Normalmente este contraste de hipótesis utiliza un estadístico similar a la t-student. Se fija un nivel de significancia y se calcula el correspondiente p-valor (y p-valor corregido para el testeo múltiple o q-valor). Si dicho p-valor (o q-valor) es menor que el nivel de significancia se asume que el correspondiente gen se expresa de forma diferencial en los genotipos/condiciones estudiadas.
- Combinación de los dos anteriores métodos



Paso 5.4: Selección de Genes Diferencialmente Expresados Método basado en fold-change

> head(expression.level)

```
WT with Fe 1 WT with Fe 2 WT no Fe 1 WT no Fe 2 pye with Fe 1 pye with Fe 2
              4.191814
                                       3.839588
                                                  3.993979
244901 at
                           4.481378
                                                                 3.822802
                                                                               4.330534
244902 at
              4.727383
                           4.933480
                                       4.537309
                                                  4.762214
                                                                4.601498
                                                                               4.939710
244903 at
              5.569595
                           6.274849
                                       5.160593
                                                  6.061207
                                                                 5.390620
                                                                               6.119615
244904 at
              5.146491
                           5.113851
                                       5.117658
                                                  5.138793
                                                                4.966478
                                                                               5.067616
                                       3.876314
244905 at
              3.869215
                           3.793270
                                                  3.776267
                                                                 3.998623
                                                                               4.182826
                                      5.826470
                                                  5.709536
244906 at
             5.746207
                           5.815738
                                                                 5.698041
                                                                               6.150307
```

> head(mean.expression)

```
WT with Fe WT no Fe pye with Fe pye no Fe per with Fe per no Fe
           4.336596 3.916784
                                           4.229890
                                                       5.618332
                                                                 6.330688
244901 at
                                 4.076668
244902 at
           4.830432 4.649761
                                 4.770604
                                           4.804530
                                                       7.792671
                                                                7.630835
244903 at
                                                       8.063286
                                                                 8.201758
           5.922222 5.610900
                                 5.755118
                                           5.577170
244904 at
           5.130171 5.128225
                                 5.017047
                                           5.257470
                                                       6.714227
                                                                 6.563183
244905 at
           3.831243 3.826290
                                 4.090725
                                           3.913093
                                                       4.740712
                                                                 4.666626
244906 at
           5.780972 5.768003
                                 5.924174
                                           5.851086
                                                       8.216157
                                                                 8.541953
```



Paso 5.4: Selección de Genes Diferencialmente Expresados

La primera columna contiene los identificadores de las sondas que representan genes

```
> head(WT.vith.no.Fe)

ID logFC AveExpr t P.Value adj.P.Val B
9650 254550_at 6.277207 6.783913 9.83369 3.645075e-07 4.157208e-04 6.467981
8602 253502_at 6.265717 4.816715 33.08769 2.400984e-13 5.476646e-09 13.629654
12235 257135_at 5.794304 5.653286 24.50304 9.001222e-12 1.026589e-07 12.580207
10624 255524_at 4.754619 5.830145 20.50022 7.605795e-11 5.782940e-07 11.731873
17473 262373_at 4.478431 6.170963 18.56509 2.470630e-10 1.408877e-06 11.181815
6083 250983_at 4.200265 7.327805 16.54205 9.640295e-10 3.299739e-06 10.471151
```



Paso 5.4: Selección de Genes Diferencialmente Expresados

La segunda columna contiene para cada sonda/gen el fold-change en log2 entre las condiciones/genotipos estudiados.

```
> head(WT.with.no.Fe)

ID logFC AveExpr t P.Value adj.P.Val B
9650 254550_at 6.277207 6.783913 9.83369 3.645075e-07 4.157208e-04 6.467981
8602 253502_at 6.265717 4.816715 33.08769 2.400984e-13 5.476646e-09 13.629654
12235 257135_at 5.794304 5.653286 24.50304 9.001222e-12 1.026589e-07 12.580207
10624 255524_at 4.754619 5.830145 20.50022 7.605795e-11 5.782940e-07 11.731873
17473 262373_at 4.478431 6.170963 18.56509 2.470630e-10 1.408877e-06 11.181815
6083 250983_at 4.200265 7.327805 16.54205 9.640295e-10 3.299739e-06 10.471151
```



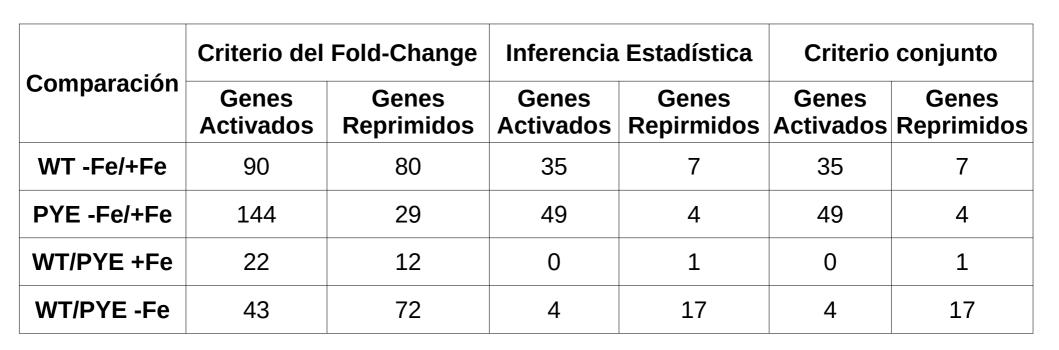
Paso 5.4: Selección de Genes Diferencialmente Expresados

Las columnas 5 y 6 contienen los p-valores y p-valores corregidos (según el FDR, false discovery rate) para los constrastes de hipótesis realizados entre las replicas de las distintas condiciones/genotipos

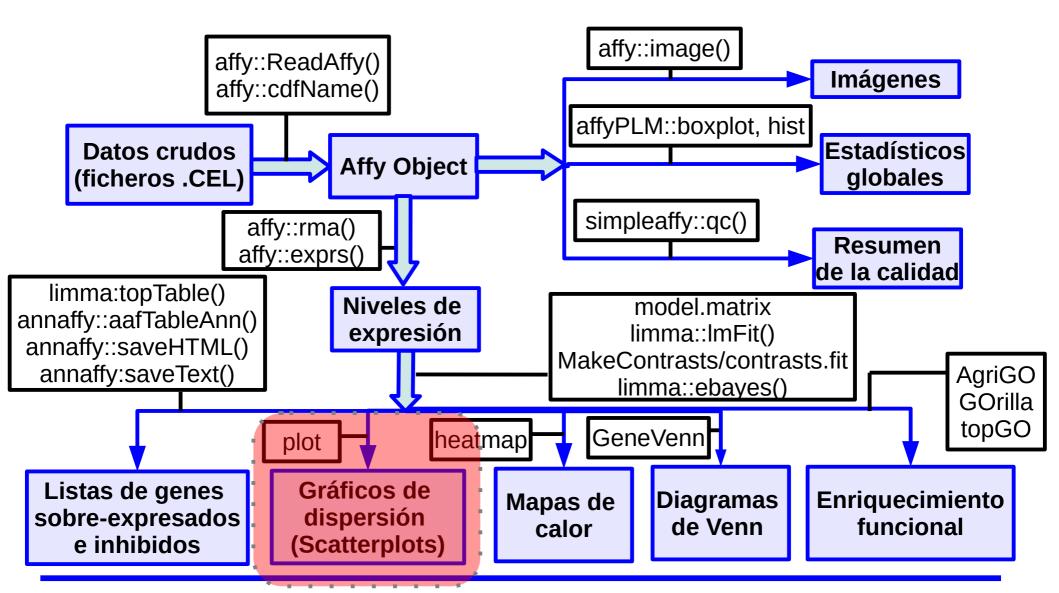


Paso 5.4: Selección de Genes Diferencialmente Expresados

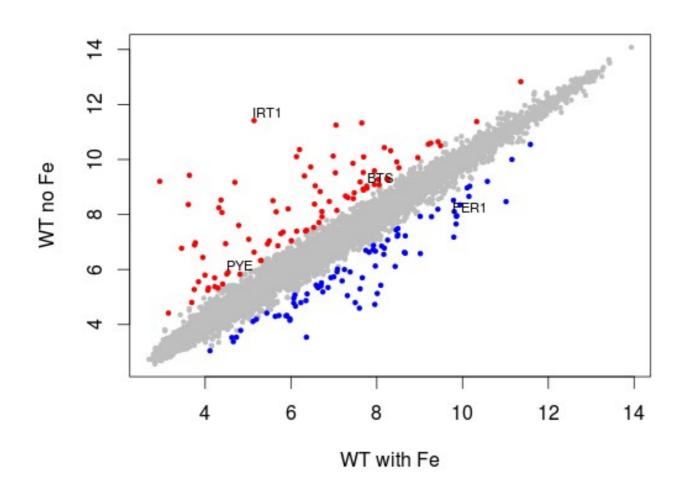
Criterio más restrictivo a aplicar cuando hay mucho ruido experimental o se trabaja con especies no modelos. No es necesario con organismos modelos.



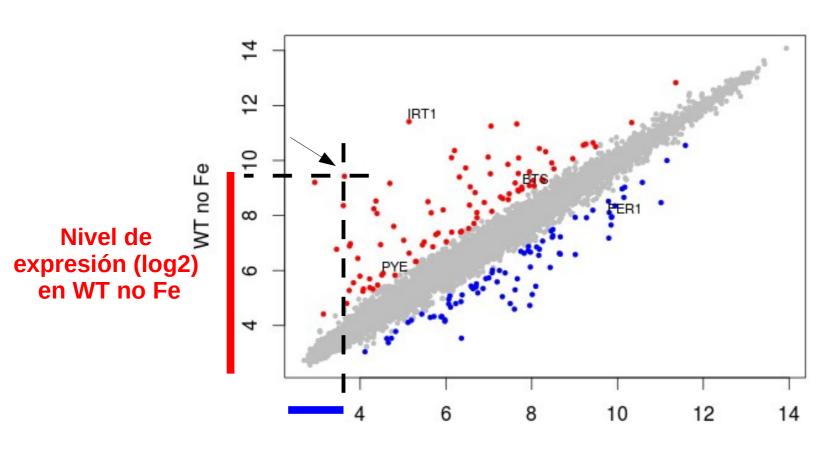






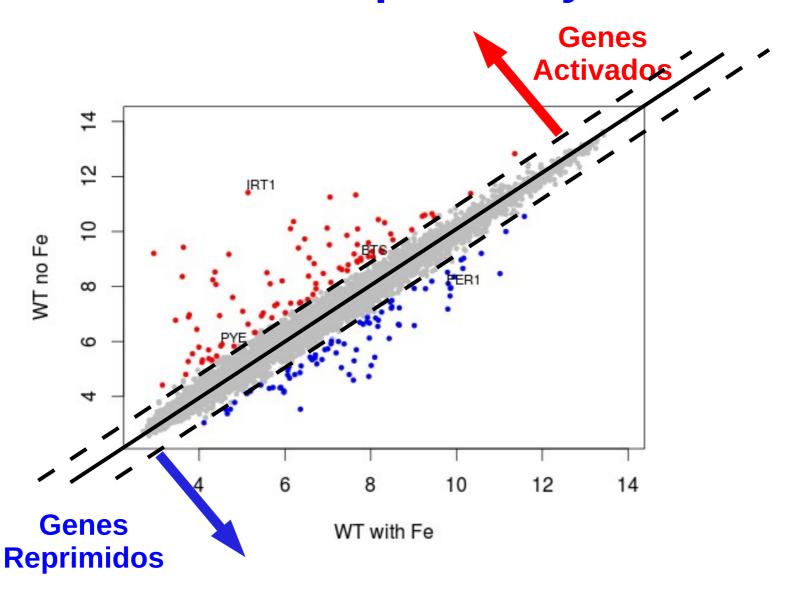




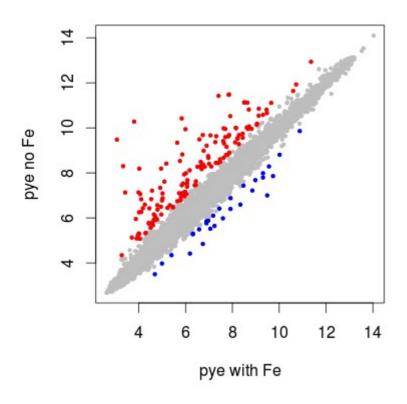


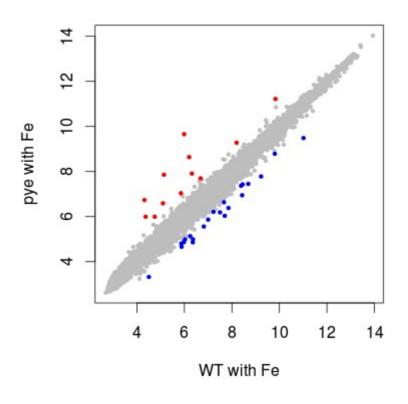
Nivel de expresión (log2) WT with Fe en WT with Fe



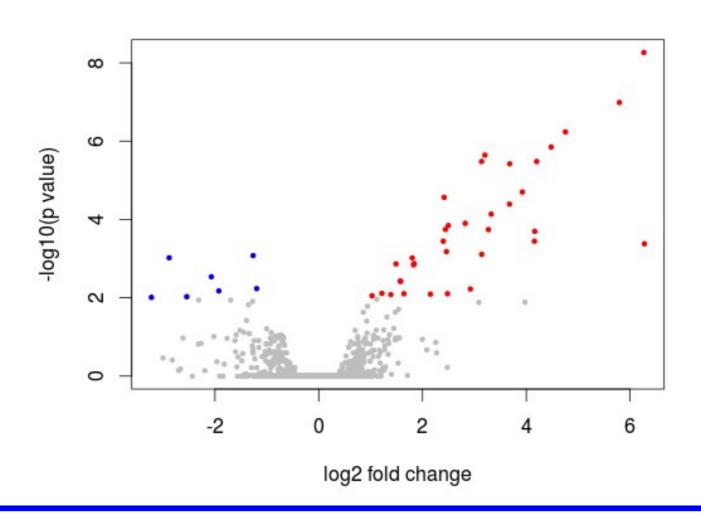




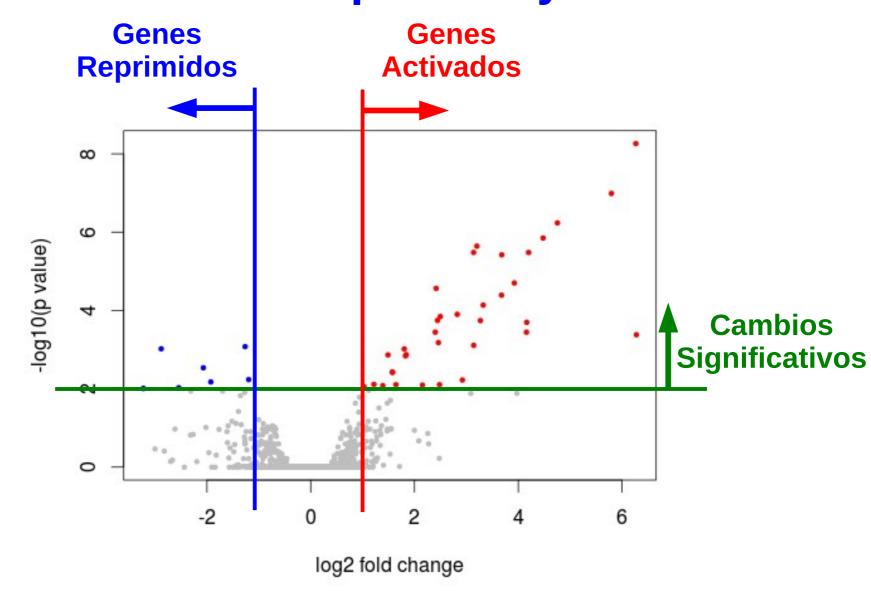






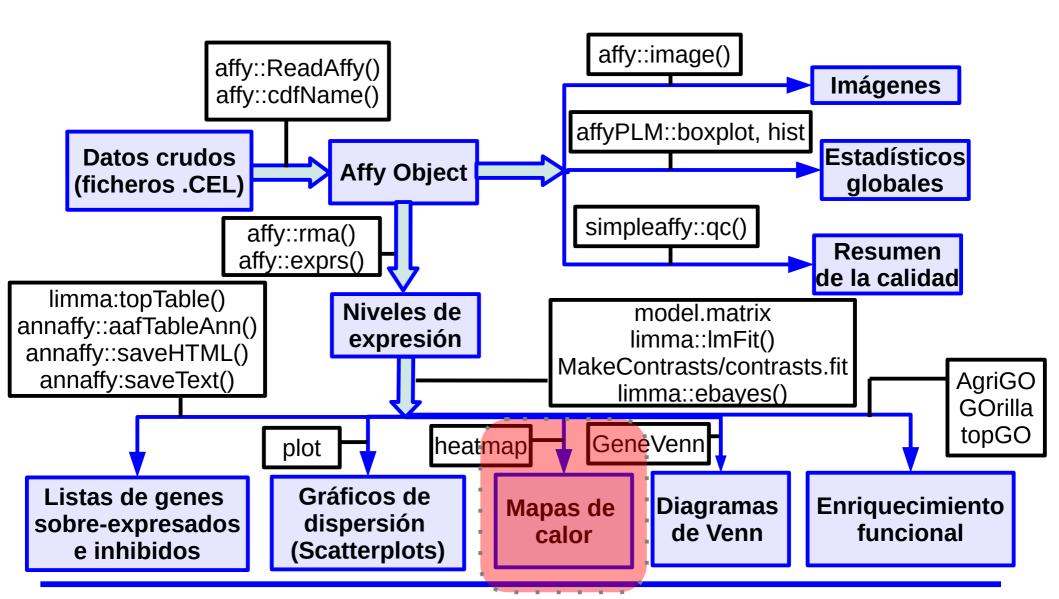




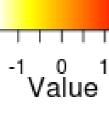


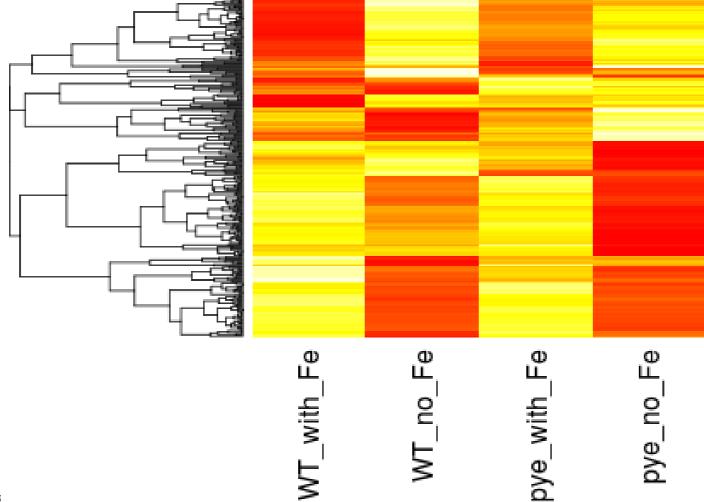


Análisis Explorativo: Mapas de calor



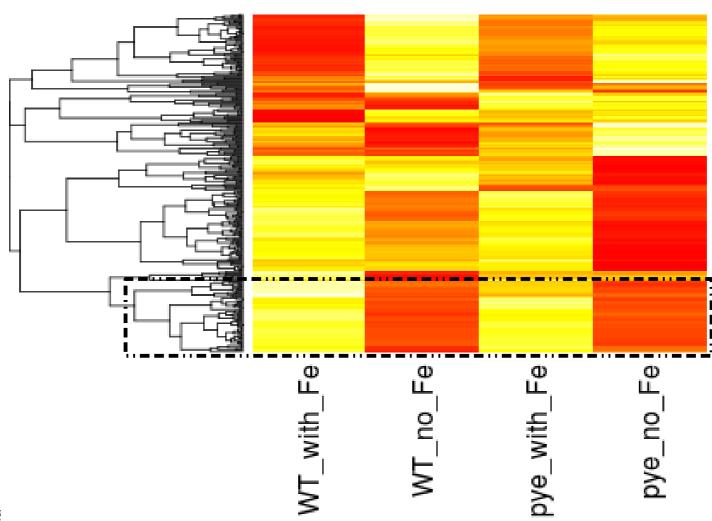






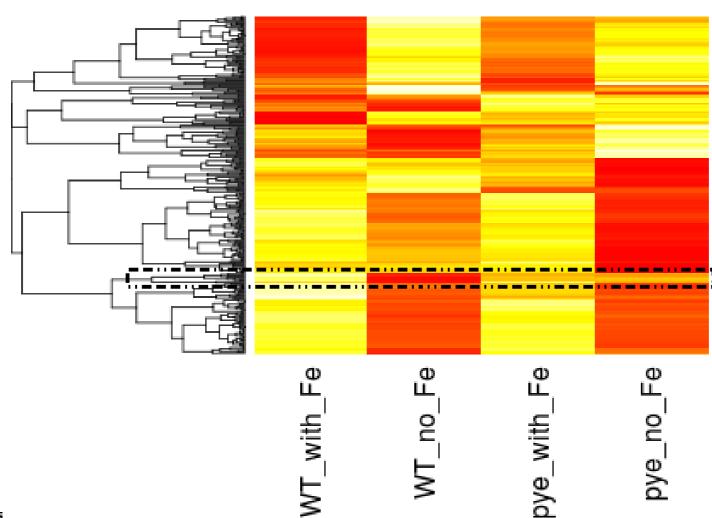


Value



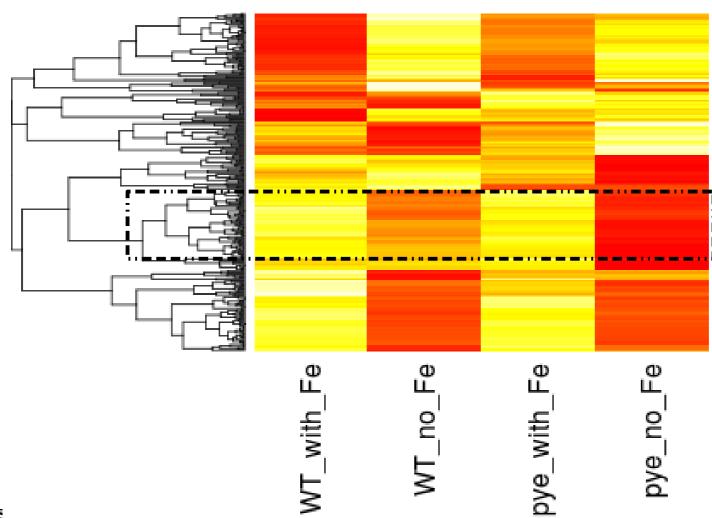


-1 0 1 Value

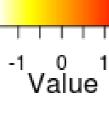


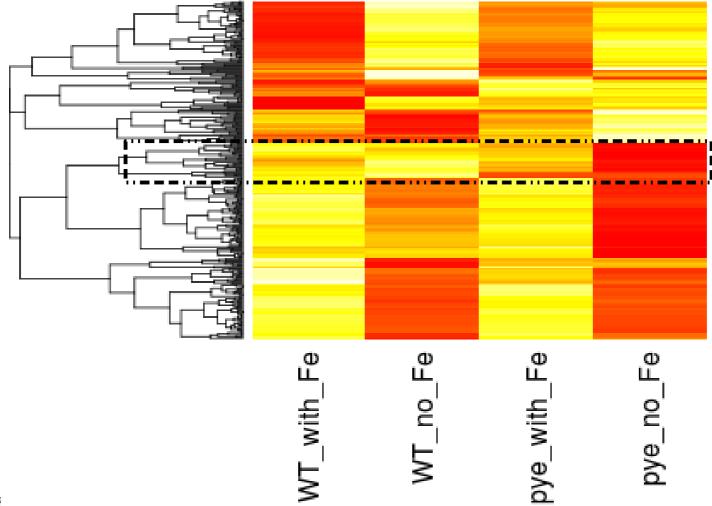


Value



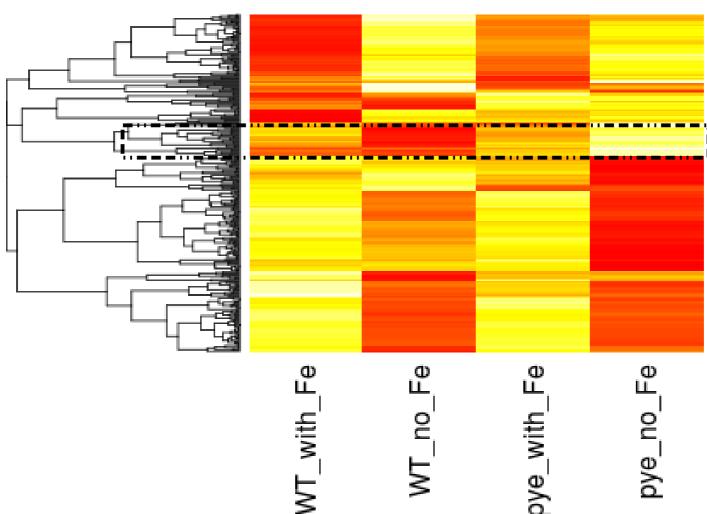






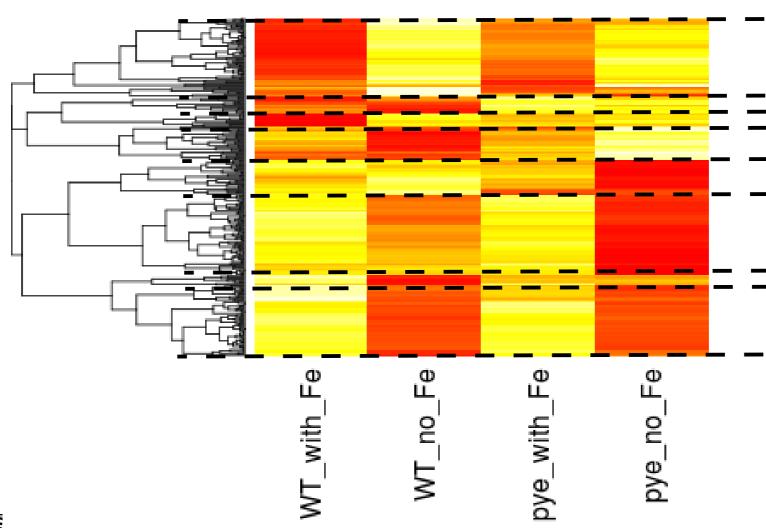


-1 0 Value

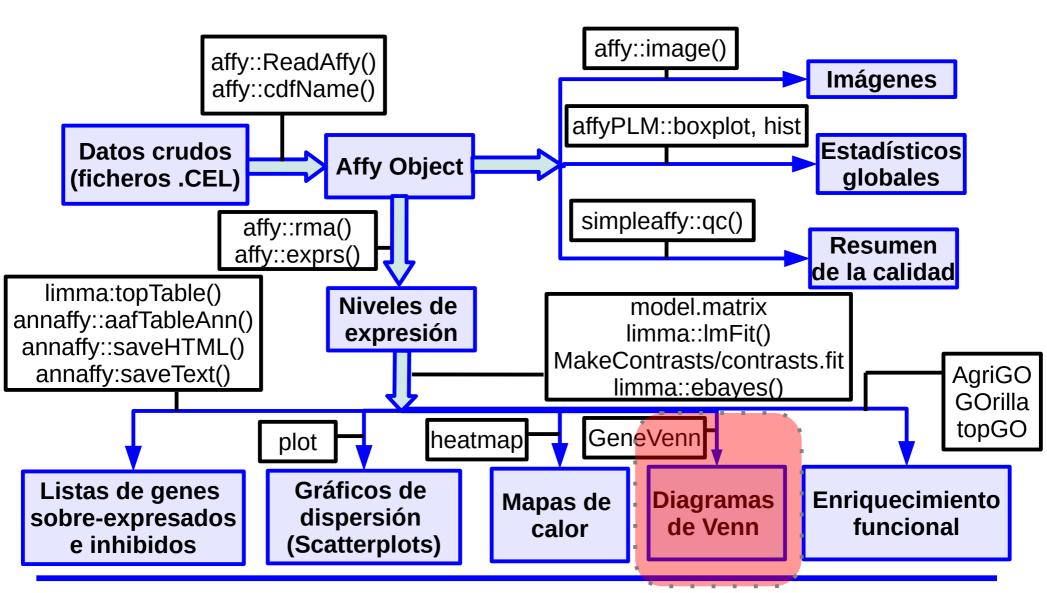




-1 0 Value

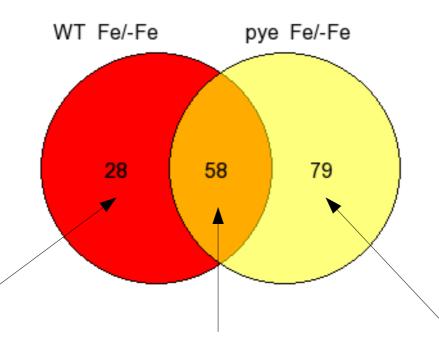








Genes Activados



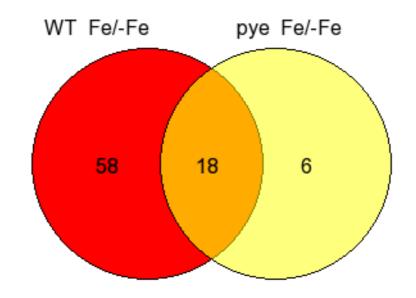
Genes activados por falta de hierro específicamente por la presencia de PYE

Genes activados por falta de hierro independientes de PYE

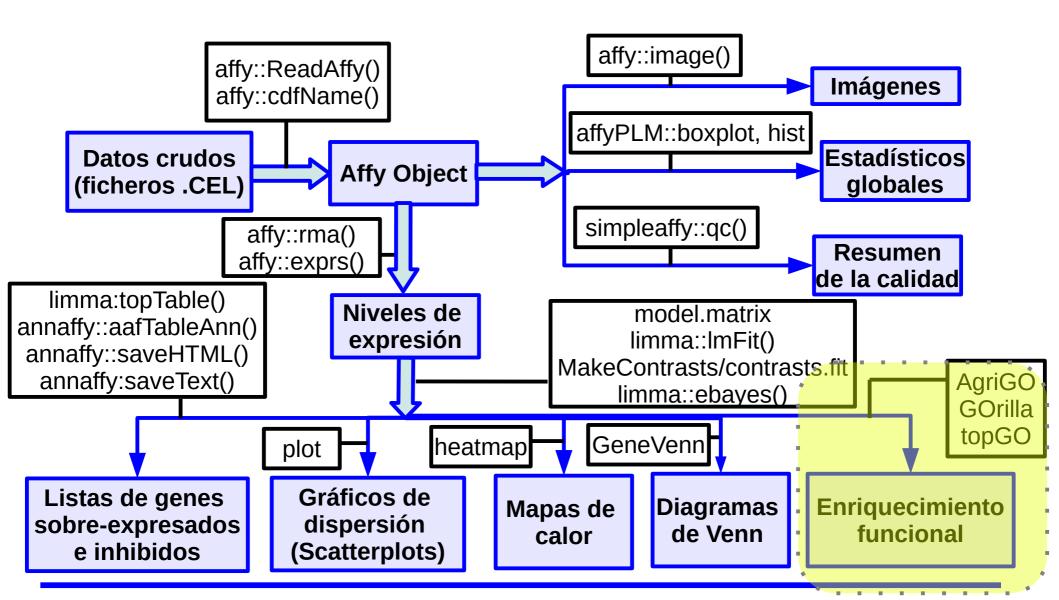
Genes activados por falta de hierro especificamente por la mutación de PYE



Genes Reprimidos









Análisis Explorativo: Enriquecimeinto de términos de Ontologías de Genes

Las ontologías de genes se desarrollaron para posibilitar la anotación (incorporación de información) a genes de forma sistemática e inequívoca.

Las **ontologías de genes** consisten en un vocabulario estructurado y controlado de términos que describen productos génicos según:

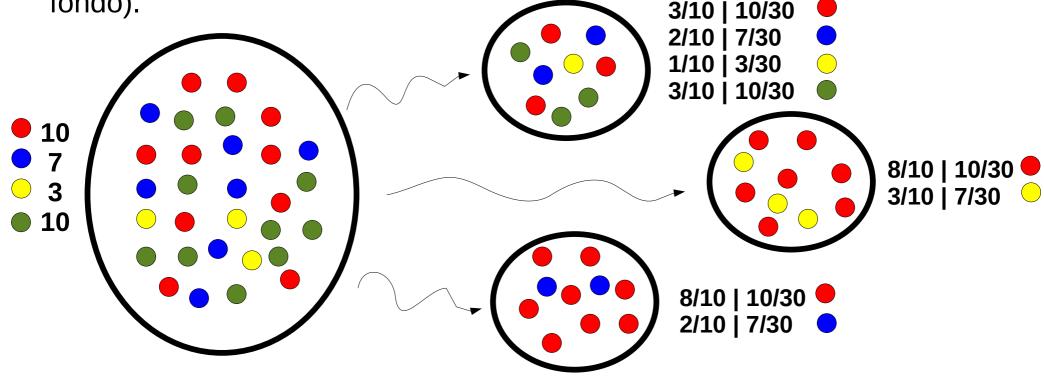
- Procesos biológicos: Una serie de eventos moleculares con principio y fin.
- Componentes celulares: Localización en estructuras celulares o macromoleculares.
- Funciones moleculares: Actividades moleculares tales como actividades enzimáticas.

http://www.geneontology.org/



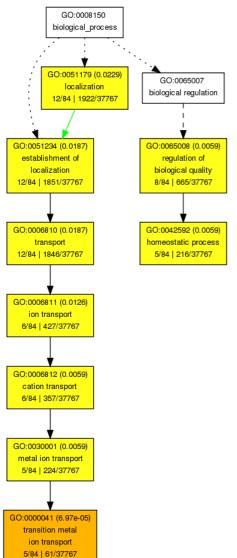
Análisis Explorativo: Enriquecimeinto de términos de Ontologías de Genes

Gene Set Enrichment Analysis (GSEA) es un método matemático/computacional que determina si en un conjunto de genes dados hay términos de GO que aparecen con significancia estadística con respecto a un conjunto de genes que representan el universo total (o fondo).





Análisis Explorativo: Enriquecimeinto de términos de Ontologías de Genes



GO term	Description	Representative genes	p-value
GO:0000041	transition metal ion transport	IREG2 IRT1 COPT2	3.8e-07
GO:0030001	metal ion transport	IREG2 IRT1 COPT2	0.00016
GO:0006811	ion transport	IREG2 IRT1 COPT2	0.00041
GO:0006812	cation transport	IREG2 IRT1 COPT2	0.00016
GO:0042592	Homeostatic process	GH3.3 ZIF1	0.00014





This work is licensed under the Creative Commons Attribution-NonCommercial-NoDerivs 3.0 Unported License. To view a copy of this license, visit http://creativecommons.org/licenses/by-nc-nd/3.0/.